



Analyse statistique Bivariée



► 2. Deux variables qualitatives

- Pour tester l'existence d'un lien entre les modalités de deux variable qualitatives:
 - On utilise de test de **CHI-2**.
 - Une représentation graphique.

► Tableau de contingence



- Pour étudier la relation entre deux variables qualitatives, on construit d'abord un tableau appelé table de contingence ou tableau croisé.

		Variable Y						
		y_1	y_2	...	y_j	...	y_m	Total
Variable X	x_1	n_{11}	n_{12}	...	n_{1j}	...	n_{1m}	$n_{1.}$
	x_2	n_{21}	n_{22}	...	n_{2j}	...	n_{2m}	$n_{2.}$
	\vdots	\vdots	\vdots	...	\vdots	...	\vdots	\vdots
	x_i	n_{i1}	n_{i2}	...	n_{ij}	...	n_{im}	$n_{i.}$
	\vdots	\vdots	\vdots	...	\vdots	...	\vdots	\vdots
	x_l	n_{l1}	n_{l2}	...	n_{lj}	...	n_{lm}	$n_{l.}$
Total		$n_{.1}$	$n_{.2}$...	$n_{.j}$...	$n_{.m}$	n

Tableau de contingence

n_{ij} : effectif joint de la modalité x_i et de la modalité y_i

n_i : effectif marginal de la modalité x_i

n_j : effectif marginal de la modalité y_i

n : taille de l'échantillon

► Tableau d'effectifs corrigés

- L'effectif corrigé se calcul ainsi:

$$n_{ij}^* = \frac{n_i n_j}{n}$$



		Variable Y						
		y ₁	y ₂	...	y _j	...	y _m	Total
Variable X	x ₁	n_{11}^*	n_{12}^*	...	n_{1j}^*	...	n_{1m}^*	$n_{1.}$
	x ₂	n_{21}^*	n_{22}^*	...	n_{2j}^*	...	n_{2m}^*	$n_{2.}$
	⋮	⋮	⋮	...	⋮	...	⋮	⋮
	x _i	n_{i1}^*	n_{i2}^*	...	n_{ij}^*	...	n_{im}^*	$n_{i.}$
	⋮	⋮	⋮	...	⋮	...	⋮	⋮
	x _l	n_{l1}^*	n_{l2}^*	...	n_{lj}^*	...	n_{lm}^*	$n_{l.}$
Total		$n_{.1}$	$n_{.2}$...	$n_{.j}$...	$n_{.m}$	n

Tableau d'effectifs corrigés

► Test de Khi-deux



Hypothèses du test:

H_0 : Les variables X et Y sont indépendantes.

H_1 : Il existe une liaison entre Les variables X et Y

Statistique du test:

Sous H_0 : $\chi^2 = \sum_{i=1}^l \sum_{j=1}^m \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} \sim \chi_{(l-1)(m-1)}^2$

Règle de décision:

Si la valeur de la statistique de test χ^2 est **inférieure** à la valeur seuil $\chi_{(l-1)(m-1)}^2$ alors on accepte l'hypothèse nulle.

Si la valeur de la statistique de test χ^2 est **supérieure** à la valeur seuil $\chi_{(l-1)(m-1)}^2$ alors on rejette l'hypothèse nulle.

Exemple:



Exposition	Etat du système immunitaire		Total
	I^-	I^+	
Exposé	135	120	255
Non exposé	150	195	345
Total	285	315	600



Exposition	Etat du système immunitaire		Total
	I^-	I^+	
Exposé	121.1	133.9	255
Non exposé	163.9	181.1	345
Total	285	315	600

Croisement entre l'exposition au produit chimique et l'état du système immunitaire

Tableau de contingence théorique

$$\text{Sous } H_0: \chi^2 = \sum_{i=1}^l \sum_{j=1}^m \frac{(n_{ij} - n_{ij}^*)^2}{n_{ij}^*} \sim \chi_{(2-1)(2-1)}^2$$

Pour un risque $\alpha = 0.05$, la région critique conduisant au rejet de H_0 pour une loi du χ_1^2 est défini par : $[3,841, +\infty[$

Application numérique:

$$\chi^2 = \frac{(135 - 121.1)^2}{121.1} + \frac{(120 - 133.9)^2}{133.9} + \frac{(150 - 163.9)^2}{163.9} + \frac{(195 - 181.1)^2}{181.1} = 5.36$$

Au risque $\alpha = 0,05$, la valeur 5,36 appartient à la zone critique. On rejette alors H_0



Illustration graphique



- Graphiquement, nous pouvons aussi déduire l'existence de relation entre deux variables qualitatives en utilisant:

le diagramme en barre regroupé




Diagramme en mosaïque

